

Teoría Econométrica I - EAE- 250-A

El modelo de regresión lineal

Tatiana Rosá

Instituto de Economía - Pontificia Universidad Católica de Chile

Agosto - Septiembre 2021

Esperanza condicional

- La **esperanza condicional de Y (escalar) dado X (vector en \mathbb{R}^k)** es un mapping o función escalar que se escribe:

$$\mathbb{E}(Y|X) : \mathbb{R}^k \rightarrow \mathbb{R}$$

- Representa el primer momento de la distribución condicional de Y en X
- Dado que X no es fijo, la esperanza condicional se convierte en una variable aleatoria que es función de X

⇒ De hecho estamos refiriendo a $E(Y|X = X_0) \forall X_0$ realizaciones de X

$$\mathbb{E}(Y|X) = \begin{cases} E(Y|X = X_1) & \text{con probabilidad } P(X = X_1) \\ E(Y|X = X_2) & \text{con probabilidad } P(X = X_2) , \\ \vdots & \vdots \end{cases}$$

Con VA continuas

- **Ejemplo VA discretas:**

- Y: rendimiento en el curso de Econometría I (4,0 ; 5,0; 5,5; 6,0)
- X: altura (1,30; 1,50; 1,70; 1,90)

- La relación entre las distintas alturas y el rendimiento econometría puede o no entregar una relación **causal**
- Pero si tenemos la distribución conjunta podemos obtener la $E(\text{NotaEcl}|\text{Altura})$
- **VA continuas:**
- La esperanza condicional se escribe simplemente de la siguiente manera si la variable aleatoria es continua:

$$\mathbb{E}(Y|X) = \int_{-\infty}^{\infty} \frac{yf(x, y)}{f(x)} dy$$

Otros momentos de interés

(1) **Efecto Parcial** de X_j sobre $\mathbb{E}(Y|X)$:

$$\frac{\partial \mathbb{E}(Y|X)}{\partial X_j}$$

El efecto parcial es marginal si queremos efectos de cambios mayores, “ ΔX_j ”

$$\frac{\Delta \mathbb{E}(Y|X)}{\Delta X_j} \approx \frac{\partial \mathbb{E}(Y|X)}{\partial X_j} \Delta X_j$$

(2) **Elasticidad**: cambios porcentuales

$$\xi_{\mathbb{E}(Y|X), X} = \frac{\partial \mathbb{E}(Y|X)}{\partial X_j} \frac{X_j}{\mathbb{E}(Y|X)}$$

- Esta expresión también puede ser escrita como:

$$\xi_{\mathbb{E}(Y|X), X} = \frac{\partial \ln \mathbb{E}(Y|X)}{\partial \ln X_j}$$

Otros objetos de interés

- Notar que:

$$\xi_{\mathbb{E}(Y|X),X} = \frac{\partial \ln \mathbb{E}(Y|X)}{\partial \ln X_j} \neq \frac{\partial \mathbb{E}(\ln Y|X)}{\partial \ln X_j}$$

- **Salvo en este caso particular:**

- (i) Supongamos un modelo expresado en logaritmo (su variable dependiente):

$$\ln(y) = g(x) + \mu$$

donde μ es independiente de X con media 0. Por simplicidad supongamos que x es escalar.

- (ii) Tomamos exponenciales:

$$y = \exp(g(x)) * \exp(\mu)$$

- (iii) Por lo tanto,

$$\mathbb{E}[y|x] = \exp(g(x)) * \mathbb{E}(\exp(\mu)|x)$$

La elasticidad queda:

$$\begin{aligned} \frac{\partial \mathbb{E}(Y|X)}{\partial X_j} \frac{X_j}{\mathbb{E}(Y|X)} \xi &= \frac{\cancel{\exp(g(x))} g'(x) \cancel{\mathbb{E}(\exp(\mu))}}{\cancel{\exp(g(x))} \mathbb{E}(\exp(\mu))} \frac{x}{\cancel{\exp(g(x))} \mathbb{E}(\exp(\mu))} \\ \xi &= g'(x)x \end{aligned}$$

Otros objetos de interés

- Ahora el modelo en logaritmos:

$$\mathbb{E}[\ln(y)|x] = g(x)$$

$$\mathbb{E}[\ln(y)|x] = g(\exp(\ln(x)))$$

$$\frac{\partial \mathbb{E}[\ln(y)|x]}{\partial \ln(x)} = g'(x) \exp(\ln(x))$$

$$\xi = g'(x)x$$

Otros objetos de interés

(3) **Semi Elasticidad:** Se define como

$$\text{Semielasticidad} = \frac{\partial \mathbb{E}(Y|X)}{\partial X_j} \frac{1}{\mathbb{E}(Y|X)}$$

- Un ejemplo de semielasticidad la podemos encontrar en el efecto marginal de la escolaridad en el ingreso, ya que la variable escolaridad está medida en niveles, y la de ingreso en logaritmos.

Ley de esperanzas iteradas

- **Ley de Esperanzas Iteradas:** En su versión más sencilla esta enuncia que:

$$\mathbb{E}_x(\mathbb{E}(y|x)) = \mathbb{E}(y)$$

- **Demostración** (en variable continua):

$$\mathbb{E}_x(\mathbb{E}(y|x)) = \int \left[\int y \frac{f(x, y)}{f(x)} dy \right] f(x) dx$$

$$\mathbb{E}_x(\mathbb{E}(y|x)) = \int \int y \frac{f(x, y)}{f(x)} f(x) dx dy$$

$$\mathbb{E}_x(\mathbb{E}(y|x)) = \int y \left[\int f(x, y) dx \right] dy$$

$$\mathbb{E}_x(\mathbb{E}(y|x)) = \int y f(y) dy \text{ porque } \int f(x, y) dx = f(y)$$

$$\mathbb{E}_x(\mathbb{E}(y|x)) = \mathbb{E}(y)$$

Notación

- Para una muestra de n observaciones el modelo (poblacional) es:

$$Y = X\beta + U$$

con

$$Y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} x_1^\top \\ \vdots \\ x_n^\top \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1k-1} \\ \vdots & \ddots & \cdots & \vdots \\ 1 & x_{n1} & \cdots & x_{nk-1} \end{pmatrix},$$
$$U = \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} = \begin{pmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

- k denota al número de variables explicativas (incluyendo la constante)

Supuestos

1. $\mathbb{E}(Y|X) = X\beta$ **Linealidad en los parámetros**
2. $V(Y) = \mathbb{E}([(y - \mathbb{E}(y))(y - \mathbb{E}(y))']) = \sigma^2 I$ **Homocedasticidad y no autocorrelación** en el término de error
3. Observaciones provenientes de una **muestra aleatoria**
o Regresores determinísticos (No estocásticos) \Rightarrow **muy de momento!!**
En este ultimo caso: $\mathbb{E}(Y|X) = \mathbb{E}(Y) = X\beta$
4. **Condición de Identificación** Matriz X de Rango Completo (mínimo de columnas o filas linealmente independiente). No puede haber multicolinealidad perfecta. En otras palabras, que $X'X$ sea invertible.
5. **Independencia / Ortogonalidad:** $\mathbb{E}(U|X) = 0$

Paradigma Estadístico

- El paradigma estadístico dice que una variable aleatoria la podemos descomponer en su esperanza condicional más un residuo.
- Este residuo cumple una propiedad conocida:

$$y = \mathbb{E}[y|x] + \varepsilon$$

donde $\mathbb{E}(\varepsilon|x) = 0$.

- Luego los supuestos los podemos expresar en función de ε

$$\varepsilon = Y - \mathbb{E}(Y|X)$$

$$\varepsilon = Y - X\beta$$

- En esta notación los supuestos son:
 1. Linearidad en los parámetros
 2. Esperanza lineal: $\mathbb{E}(\varepsilon|X) = \mathbb{E}\mathbb{X} = 0$
 3. $V(\varepsilon) = \sigma^2 I_n$
 4. Muestra Aleatoria (vs. regresores determinísticos)
 5. Rango completo de $X(k)$

Derivación del estimador de MCO/OLS

- El estimador de MCO es aquel que minimiza la suma de los errores al cuadrado;

$$\operatorname{argmin}_{\beta} S = \sum_{i=1}^n \varepsilon_i^2 = \varepsilon' \varepsilon = (Y - X\beta)'(Y - X\beta)$$

- Se podría haber elegido otra métrica!

⇒ Ejemplo:

$$\operatorname{argmin}_{\beta} S^* = \sum_{i=1}^n |\varepsilon_i|$$

⇒ Se conoce como Least Absolute Deviations (LAD)

⇒ Pasa por las medianas y es insensible a outliers, pero propiedades difíciles de demostrar

Optimización

- Recuerde que escribimos el criterio de minimización y lo derivamos con respecto a β

$$S = (Y - X\beta)'(Y - X\beta) = Y'Y - 2Y'X\beta + \beta'X'X\beta$$

⇒ Usamos las reglas de derivación que puede ver en el apéndice del Wooldridge/Greene

- Si A es una matriz simétrica y \mathbf{x} un vector y los productos $A\mathbf{x}$ y $\mathbf{x}'A\mathbf{x}$ son conformables, tenemos que:

$$\frac{\partial A\mathbf{x}}{\partial \mathbf{x}} = A'$$

$$\frac{\partial \mathbf{x}'A\mathbf{x}}{\partial \mathbf{x}} = (A' + A)\mathbf{x} = 2A\mathbf{x}$$

Optimización

- Aplicamos cálculo diferencial matricial a S tenemos la ecuación normal:

$$\begin{aligned}\mathbf{0} &= \mathbf{X}'(\mathbf{Y} - \mathbf{X}\hat{\beta}) \\ \hat{\beta} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} \\ &= \left(\frac{1}{N} \sum_{i=1}^N x_i' x_i \right)^{-1} \left(\frac{1}{N} \sum_{i=1}^N x_i' y_i \right).\end{aligned}$$

- Donde x_i es un vector de $1 \times k$ con la i -ésima observación para los k regresores.
- Estas son las dos representaciones típicas del estimador OLS de β .

Derivación desde la estadística

- Es posible encontrar un estimador por el Principio de la Analogía o Método de Momentos explotando el supuesto de identificación $\mathbb{E}(\epsilon|x) = 0$

$$y = \mathbf{x}\beta + \epsilon$$

con \mathbf{x} vector de $1 \times k$ (una sola observación)

- El supuesto de identificación de MCO implica que

$$\mathbb{E}(\mathbf{x}'\epsilon|\mathbf{x}) = 0$$

- β puede ser expresado en momentos de las variables observables:

$$\mathbf{x}'y = \mathbf{x}'\mathbf{x}\beta + \mathbf{x}'\epsilon$$

tomando valor esperado tenemos que:


$$\beta = \mathbb{E}(\mathbf{x}'\mathbf{x}|\mathbf{x})^{-1} \mathbb{E}(\mathbf{x}'y|\mathbf{x})$$

- El *analogy principle* (Goldberger (1968), Manski (1988)) implica

$$\hat{\beta}_{MM} = \hat{\beta}_{MCO} = \left[\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i' \mathbf{x}_i \right]^{-1} \left[\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i' y_i \right] \equiv (X'X)^{-1} X'Y$$

Interpretación geométrica del estimador MCO

- Se define $P = X(X^T X)^{-1} X^T$, matriz de proyección en el espacio generado por las columnas de X .
- Se define $M = I - P$, matriz de proyección en el espacio ortogonal al espacio generado por las columnas de X .
- $\hat{Y} = X\hat{\beta} = X(X^T X)^{-1} X^T Y = PY$
- $\hat{U} = Y - \hat{Y} = Y - X\hat{\beta} = Y - X(X^T X)^{-1} X^T Y = Y - PY = MY$
- $Y = \hat{Y} + \hat{U} = PY + MY$ es la descomposición del vector y en dos espacios ortogonales.
- Las matrices P y M verifican dos propiedades:
 - Son simétricas: $P^T = P, M^T = M$
 - Son idempotentes: $P^2 = P, M^2 = M$



Bondad de Ajuste

- Si la primera columna de \mathbf{X} es una vector columna “1” igual a 1, se tiene una medida resumen para la “bondad de ajuste” de los valores predichos de la siguiente identidad:

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

$$\begin{aligned} SST &= SSR + SSE \\ 1 &= \frac{SSR}{SST} + \frac{SSE}{SST} \end{aligned}$$

- Donde
 - SST: suma la variación total del modelo (suma cuadrados totales)
 - SSR: suma de los residuos al cuadrado
 - SSE: Suma explicada por el modelo

La medida de bondad de ajuste es

$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$

En términos matriciales

- Matricialmente,

$$\begin{aligned} R^2 &\equiv 1 - \frac{(\mathbf{y} - \mathbf{X}\hat{\beta})'(\mathbf{y} - \mathbf{X}\hat{\beta})}{(\mathbf{y} - \bar{y}\boldsymbol{\iota})'(\mathbf{y} - \bar{y}\boldsymbol{\iota})} \\ &= 1 - \frac{\hat{\epsilon}'\hat{\epsilon}}{(\mathbf{y} - \bar{y}\boldsymbol{\iota})'(\mathbf{y} - \bar{y}\boldsymbol{\iota})} \end{aligned}$$

- donde \bar{y} es el promedio muestral (escalar) de la variable dependiente,

$$\bar{y} \equiv \frac{1}{N} \sum_i Y_i$$

- y $\boldsymbol{\iota}$ es un vector de unos de dimensión N .

Sobre el R cuadrado:

1. El coeficiente de determinación es siempre menor a 1. Ello porque $SSR \leq SST$ y por lo tanto $\frac{SSR}{SST} \leq 1$.
2. El análisis de varianza anterior fue derivado bajo el supuesto que el modelo incluía una constante. También tenemos $R^2 \geq 0$.
3. Al agregar regresores al modelo, el R^2 nunca decrecerá (se mantendrá constante o aumentará).
4. No es claro cuan bueno sea como predictor de ajuste.

También está el R^2 ajustado :

- El R^2 ajustado, \bar{R}^2 se define:

$$\bar{R}^2 = 1 - \frac{SSR/(n-k)}{SST/(n-1)}$$

Regresión Particionada

- Al particionar la matriz de regresores podemos escribir X como la *concatenación horizontal* de dos sub-matrices

$$X \equiv [X_1 \ X_2]$$

- Donde X_1 es de $n \times k_1$ y X_2 de $n \times k_2$ con $k_1 + k_2 = k$ lo que, junto con una versión particionada del estimador OLS

$$\hat{\beta} \equiv \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix}$$

- Así, el modelo de regresión lineal se puede escribir de la siguiente manera

$$Y = X_1\beta_1 + X_2\beta_2 + \epsilon$$

Regresión Particionada

- Esta notación hace posible que podamos derivar una relación entre el subvector $\hat{\beta}_1$ de la regresión “larga” (de y sobre X_1 y X_2) y los coeficientes de la regresión “corta” (de y sobre X_1),

$$\hat{\beta}_1^* \equiv (X_1' X_1)^{-1} X_1' Y$$

- donde $\hat{\beta}_1^*$ solamente usa la submatriz X_1 de regresores.

$$\hat{\beta}_1^* = \hat{\beta}_1 + (X_1' X_1)^{-1} X_1' X_2 \hat{\beta}_2$$

- donde la relación anterior viene de reemplazar $Y = X_1 \hat{\beta}_1 + X_2 \hat{\beta}_2 + \hat{\epsilon}$ en el coeficiente de la regresión “corta”.
- Si $X_1' X_2 \neq 0$ y $\hat{\beta}_2 \neq 0$ el término $(X_1' X_1)^{-1} X_1' X_2 \hat{\beta}_2$ corresponde al *sesgo por omisión de variables relevantes*

Teorema de Frisch-Waugh-Lovell

- Sea P_i la matrix de proyección en el subespacio generado por X_i , y $M_i = I - P_i$ la matrix que proyecta en el subespacio ortogonal al generado por X_i

$$P_i \equiv X_i(X_i'X_i)^{-1}X_i' ; M_i \equiv I - (X_i(X_i'X_i)^{-1}X_i')$$

- Teorema FWL:** Los coeficientes de la regresión larga pueden ser escritos como:

$$\hat{\beta}_1 = (X_1'M_2M_2X_1)^{-1}X_1'M_2M_2Y$$

- Nos dice que podemos hallar los estimadores en dos etapas (regresando X_1 en X_2 y Y en X_2)
- Solían considerarse separadas la constante y una tendencia determinística y la interpretación era la de Y sin tendencia temporal
- Utilidad cuando invertir matrices mu grandes era un problema computacional importante

Momentos de los estimadores OLS

- Las reglas para el cálculo de la media (vector) y matriz de varianzas y covarianzas de una función lineal $\mathbf{A}\mathbf{y}$ de un vector aleatorio \mathbf{y} (con \mathbf{A} no estocástica) son:

$$\mathbb{E}[\mathbf{A}\mathbf{y}] = \mathbf{A}\mathbb{E}[\mathbf{y}]$$

$$V[\mathbf{A}\mathbf{y}] = \mathbf{A}V[\mathbf{y}]\mathbf{A}'$$

- \Rightarrow Recordamos: cuando condicionamos en una V.A, podemos tratar esa V.A como “no estocástica” (en esa condición)
- Aplicando estas reglas al estimador OLS $\hat{\beta}$, bajo los supuestos estándar, tenemos que

$$\begin{aligned}\mathbb{E}[\hat{\beta}|X] &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\mathbf{Y}|X] \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\beta \\ &= \beta\end{aligned}$$

- esto significa que el estimador OLS $\hat{\beta}$ es insesgado.

Varianza del estimador OLS

- Por otro lado, tenemos que

$$\begin{aligned}V[\hat{\beta}|X] &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'V[\mathbf{Y}|X]\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\&= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'[\sigma^2\mathbf{I}]\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\&= \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\end{aligned}$$

- De forma similar es posible demostrar que s^2 es un estimador insesgado de σ^2 , siendo s^2

$$s^2 \equiv \frac{1}{N-K} (\mathbf{y} - \mathbf{X}\hat{\beta})' (\mathbf{y} - \mathbf{X}\hat{\beta})$$

- Tarea: demostrar que $\mathbb{E}[s^2] = \sigma^2$. Hint: La demostración implica intercambiar el operador traza y esperanza convenientemente además del uso de propiedades como $tr(AB) = tr(BA)$, etc.

Gauss–Markov

- Bajo los supuestos vistos, los estimadores OLS son MELI o (BLUE)
- El término Mejor hace referencia a el más eficiente, de menor varianza
- Esto lo demuestra el teorema de Gauss–Markov:

1. Sea $\tilde{\beta} = m + MY$ un estimador lineal de Y
2. Buscamos entre los estimadores insesgados, entonces: $\mathbb{E}(\tilde{\beta}) = \beta$
3. Entonces

$$\begin{aligned}\mathbb{E}(\tilde{\beta}|X) &= m + M\mathbb{E}(Y|X) \\ &= M\mathbb{E}(X\beta + \varepsilon|X) \\ &= m + MX\beta\end{aligned}$$

4. : Esto implica que:

$$m = 0 \text{ y que } MX = I_k$$

\Rightarrow Notar que pasa cuando definimos $M = (X'X)^{-1}X'$

5. WLOG, podemos definir $M = (X'X)^{-1}X' + C$

Gauss–Markov

6. Tenemos entonces:

$$\begin{aligned}MX &= I_k \\ \Rightarrow ((X'X)^{-1}X' + C)X &= I_k \\ \Rightarrow I_k + CX &= I_k \\ \Rightarrow CX &= 0\end{aligned}$$

7. Podemos escribir $\tilde{\beta}$ en términos de β para computar luego su varianza:

$$\begin{aligned}\tilde{\beta} &= MY \\ &= M(X\beta + \varepsilon) \\ \Rightarrow \tilde{\beta} - \beta &= M\varepsilon\end{aligned}$$

8. Entonces computamos la varianza condicional en X

$$\begin{aligned}\text{Var}(\tilde{\beta}|X) &= \mathbb{E}((\tilde{\beta} - \beta)(\tilde{\beta} - \beta)'|X) \\ &= \mathbb{E}(M\varepsilon(M\varepsilon)'|X) \\ &= \mathbb{E}(M\varepsilon\varepsilon'M'|X)\end{aligned}$$

Gauss–Markov

Seguimos...

$$\begin{aligned}\text{Var}(\tilde{\beta}|X) &= M\mathbb{E}(\varepsilon\varepsilon'|X)M' \\ &= M\sigma^2 I_n M' \\ &= \sigma^2 MM'\end{aligned}$$

9. Descomponemos MM'

$$\begin{aligned}MM' &= ((X'X)^{-1}X' + C)((X'X)^{-1}X' + C)' \\ &= (X'X)^{-1}X'X(X'X)^{-1} + (X'X)^{-1}X'C' + CX(X'X)^{-1} + CC' \\ &= (X'X)^{-1} + CC'\end{aligned}$$

10. Y CC' es una matriz de productos cruzados por tanto semidefinida positiva

El Modelo Normal de Regresión Lineal

- Hasta aquí no hemos asumido una distribución para el término de error
- La ventaja de asumir normalidad es que podemos hacer inferencia exacta, es decir, tendremos estadísticos cuya distribución no depende de aproximaciones asintóticas
- Van a tener “buenas propiedades” incluso en muestra finita
- Para lograr esto, debemos aumentar en un supuesto el modelo anterior. Este modelo fue propuesto por Gauss en 1809 varios años después de que Legendre propusiera el estimador de MCO.
- **Supuesto 6: Normalidad.** El vector Y (o equivalentemente $\epsilon = Y - X\beta$) tiene una distribución normal multivariada.
Luego, bajo los supuestos 1-6, la distribución del vector y es

$$y \sim \mathcal{N}(X\beta, \sigma^2 I)$$

y

$$\epsilon \sim \mathcal{N}(0, \sigma^2 I)$$

Estimador OLS también es el estimador de máxima verosimilitud

- Bajo los supuestos anteriores Gauss en 1809 derivó el estimador MCO del modelo como un estimador de Máxima Verosimilitud para este modelo.
- Es fácil darse cuenta que

$$L = f(y_1, y_2, \dots, y_n; X, \sigma^2, \beta) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp^{-\frac{(Y-X\beta)'(Y-X\beta)}{2\sigma^2}}$$

con lo cual, el estimador $\hat{\beta}_{MV}$ se obtiene maximizando:

$$\begin{aligned} \max_{\beta, \sigma^2} \ln(L) &= \max_{\beta, \sigma^2} \ln \left(\frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp^{-\frac{(Y-X\beta)'(Y-X\beta)}{2\sigma^2}} \right) \\ &= \max_{\beta, \sigma^2} \left(-\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{(Y-X\beta)'(Y-X\beta)}{2\sigma^2} \right) \quad (1) \end{aligned}$$

$$\frac{\partial \ln L}{\partial \beta} = \frac{1}{\hat{\sigma}^2} X'(Y - X\hat{\beta}) = 0 \implies \hat{\beta}_{MV} = (X'X)^{-1}X'Y$$

- Luego, tenemos que $\hat{\beta}_{MV} = \hat{\beta}_{MCO} = \hat{\beta}$ tiene una distribución normal

$$\hat{\beta} \sim N(\beta, \sigma^2(X'X)^{-1})$$

Inferencia en el modelo normal de regresión

- El resultado anterior tiene implicancias directas. Cualquier combinación lineal de $\hat{\beta}$ tendrá una distribución normal. Así,

$$\hat{\theta} = R\hat{\beta} \sim \mathcal{N}(\theta, \sigma^2 R(X'X)^{-1}R')$$

donde $\theta = R\beta$

- El supuesto de normalidad también implica:

$$\frac{(N-K)s^2}{\sigma^2} \sim \chi^2_{N-K}$$

- Con los resultados anteriores podemos hacer inferencia exacta. Si R tiene sólo una fila (es una hipótesis lineal) tenemos que

$$\frac{\hat{\theta} - \theta}{\sqrt{s^2 R(X'X)^{-1}R'}} \sim t_{N-K}$$

Inferencia sobre más de un parámetro a la vez

- Si R tiene más de una fila, entonces $R(X'X)^{-1}R'$ no es escalar y podemos fabricar un test F. Si R tiene r filas, tenemos que

$$(\hat{\theta} - \theta)'[s^2 R(X'X)^{-1}R']^{-1}(\hat{\theta} - \theta)/r \sim F_{r, N-K}$$

- Este resultado nos sirve para testear hipótesis del tipo $H_0 : R\beta = \theta_0$ y $H_a : R\beta \neq \theta_0$ donde sólo debemos reemplazar el parámetro θ por el hipotético θ_0

Significación conjunta de todos los parametros (menos la constante)

- Un caso especial en donde la matriz \mathbf{X} esté particionada de la forma $\mathbf{X} = [\mathbf{X}_1 \mathbf{X}_2]$ y donde \mathbf{X}_1 es un vector columna de unos ($\mathbf{X}_1 = \iota$)
- Con la correspondiente partición de β , permite testear la hipótesis nula $H_0 : \beta_2 = \mathbf{0}$ usando el estadístico R^2 .
- Bajo los supuestos vistos anteriormente y la hipótesis nula recién enunciado tenemos:

$$\frac{N - K}{N - 1} \frac{R^2}{1 - R^2} \sim F_{K-1, N-K}$$

- En el caso del modelo de regresión lineal tenemos que existe una relación monótonica entre el R^2 y el estadístico F para testear que todos los coeficientes (menos el intercepto) son cero

Intervalos de confianza

- Tenemos que

$$\frac{\hat{\theta} - \theta}{\sqrt{s^2 R(X'X)^{-1} R'}} \sim t_{N-K}$$

- Entonces podemos construir un IC del $(1 - \alpha)\%$, es decir de $\alpha\%$ de significancia para θ usando los valores de tabla de la distribución t :

$$\begin{aligned} 1 - \alpha &= Pr \left[t_{N-K}^{\alpha/2} \leq \frac{\hat{\theta} - \theta}{\sqrt{s^2 R(X'X)^{-1} R'}} \leq t_{N-K}^{1-\alpha/2} \right] \\ &= Pr \left[-t_{N-K}^{1-\alpha/2} \leq \frac{\hat{\theta} - \theta}{\sqrt{s^2 R(X'X)^{-1} R'}} \leq t_{N-K}^{1-\alpha/2} \right] \\ &= Pr \left[\hat{\theta} - t_{N-K}^{1-\alpha/2} \sqrt{s^2 R(X'X)^{-1} R'} \leq \theta \leq \hat{\theta} + t_{N-K}^{1-\alpha/2} \sqrt{s^2 R(X'X)^{-1} R'} \right] \end{aligned}$$

- Tendremos así:

$$\theta \in \left[\hat{\theta} \pm t_{N-K}^{1-\alpha/2} \times \sqrt{s^2 R(X'X)^{-1} R'} \right]$$

IC para test sobre más de un parámetro

- También podemos invertir un test F.
- Tendremos “regiones de confianza” (un poco más complicado) y
- Para el caso que la matriz R tenga sólo 2 filas tiene una representación gráfica en R^2 . Las regiones de confianza serán elipses. Para ello sólo debemos notar lo siguiente:

$$Pr[(\hat{\theta} - \theta)'[s^2 R(X'X)^{-1} R']^{-1}(\hat{\theta} - \theta)/r \leq F_{r, N-K}^{1-\alpha}] = 1 - \alpha$$

luego resolvemos para el argumento y nos quedará la ecuación de una elipse.

Ejemplo regiones de confianza

- **EJEMPLO:** Considere el modelo $y = \beta_1 x_1 + \beta_2 x_2 + u$. Se quiere testear simultáneamente que $\beta_1 = r_1$ y $\beta_2 = r_2$. Note que

$$R = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

Si,

$$X'X = \begin{pmatrix} \phi_1 & \phi_2 \\ \phi_3 & \phi_4 \end{pmatrix}$$

desarrollando el argumento de la región de confianza llegamos a una ecuación de la elipse:

$$\frac{1}{s^2 r} [(\beta_1 - r_1)^2 \phi_1 + (\beta_2 - r_2)(\beta_1 - r_1)(\phi_2 + \phi_3) + (\beta_2 - r_2)^2 \phi_4 = F_{r, n-k}^{1-\alpha}]$$

Notación

Figure: Regiones de Confianza Elípticas





Figure: Regiones de Confianza Elípticas3D



Desviaciones de los Supuestos Clásicos

1. **(No Normalidad)** Si \mathbf{y} no es multinormalmente distribuida entonces la distribución **exacta** del estimador MCO (normalidad para $\hat{\beta}$ y chi-cuadrado para s^2) ya no aplica.

— Afortunadamente la teoría asintótica nos dice que $\hat{\beta}$ se distribuye aproximadamente normal y que este error de aproximación se va hacia cero cuando el tamaño muestral aumenta.

Si los supuestos estándar cumplen con las condiciones que los teoremas del límite y Slutsky requieren, entonces el estimador OLS se distribuye aproximadamente normal

$$\hat{\beta} \overset{A}{\sim} (\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$$

Desviaciones de los Supuestos Clásicos

2. **(Multicolinealidad)** Si la matriz \mathbf{X} no es de rango (columna) completo entonces la matriz $\mathbf{X}'\mathbf{X}$ no es invertible y el verdadero vector de parámetros β no puede ser identificado a partir de los datos observados
3. **(Matriz de Covarianzas No Escalar)** Cuando la matriz de covarianzas de \mathbf{y} (o ϵ) no es proporcional a una matriz identidad - $V(\mathbf{y}) \equiv \Sigma \neq \sigma^2 \mathbf{I}$ para cualquier σ^2 - entonces el estimador OLS clásico, aun cuando es lineal, deja de ser el “mejor” en su tipo
4. **(Regresores Endógenos)** Si falla el supuesto de que la esperanza de \mathbf{y} dado \mathbf{X} no es una combinación lineal de \mathbf{X} , se tiene la complicación más grave del caso OLS clásico.